

Enterprise MCP Service Bus

Uma arquitetura de referência para acesso agêntico corporativo governado por Client-Bound Entitlements

Classe de documento	Paper técnico-executivo de arquitetura
Domínio	Integração corporativa, identidade e autorização para sistemas agênticos sobre Model Context Protocol (MCP)
Natureza	Arquitetura de referência + implementação de referência executável, mantidas neste repositório
Público-alvo	Arquitetos de segurança e integração, engenharia de plataforma, liderança técnica e executiva
Repositório	github.com/mcloh/Enterprise-MCP-Service-Bus

Sumário

- 0. Resumo executivo
- 1. O problema: agentes de IA como novos consumidores de sistemas corporativos
- 2. Ideia central e analogia estrutural
- 3. Mecanismos centrais (o núcleo inventivo da arquitetura)
- 4. Arquitetura de componentes
- 5. Fluxos operacionais de ponta a ponta
- 6. Modelo de ameaças e defesa em profundidade
- 7. Evidência de implementação: da arquitetura ao sistema em funcionamento
- 8. Posicionamento comparativo
- 9. Conjunto formal de invariantes
- 10. Modelo de maturidade e trajetória de adoção
- 11. Glossário
- 12. Síntese final

0. Resumo executivo

Sistemas de IA agêntica — agentes que planejam, decidem e chamam ferramentas de forma autônoma — estão deixando de ser protótipos isolados para se tornarem consumidores regulares de sistemas corporativos: CRMs, ERPs, plataformas de pagamento, dados de clientes, sistemas de RH. O Model Context Protocol (MCP) surgiu como o padrão de fato para conectar esses agentes a "tools" — funções que um modelo de linguagem pode descobrir e invocar.

Esse novo padrão de consumo cria um problema que a integração corporativa tradicional nunca precisou resolver: **o consumidor da API agora é um componente probabilístico**. Um agente pode ser manipulado por conteúdo malicioso embutido em um documento, um e-mail, uma página web ou o resultado de uma ferramenta anterior — um ataque conhecido como *prompt injection*. Se a autorização depender, mesmo que indiretamente, de qualquer informação que o próprio agente processe ou declare, um ataque bem-sucedido contra o modelo se traduz diretamente em uma escalada de privilégio contra o negócio.

Este documento descreve uma arquitetura — o **Enterprise MCP Service Bus** — que resolve esse problema deslocando a fronteira de confiança para fora do agente. A ideia central, da qual todo o resto deriva, é simples de enunciar e difícil de violar por acidente:

A identidade autenticada do MCP Client — nunca o conteúdo processado pelo agente — define o teto máximo de capacidades que uma sessão pode exercer. Nenhuma informação controlada pelo agente pode ampliar esse teto; ela só pode restringi-lo.

A partir desse princípio único, a arquitetura constrói um barramento corporativo — inspirado no papel histórico dos Enterprise Service Bus (ESB), porém desenhado para consumo semântico por agentes — que:

- publica capacidades corporativas uma única vez e as reutiliza por assinatura governada, em vez de cada equipe construir seu próprio conector *ad hoc*;
- entrega a cada agente um **catálogo personalizado**, não o catálogo inteiro da empresa, reduzindo simultaneamente risco, custo de contexto do modelo e taxa de erro de seleção de ferramenta;
- reautoriza **toda** chamada de execução de forma independente da listagem, fechando a lacuna clássica entre "o que o agente vê" e "o que o agente pode fazer";
- permite personalização, recomendação e orquestração de jornada (incluindo o cálculo de uma *Next Best Action*) **sem nunca deixar que relevância se transforme em autorização**;

- produz uma trilha de auditoria correlacionada de ponta a ponta, do evento de negócio à decisão de política, à chamada de backend.

O resultado prático é que um comprometimento cognitivo do agente — o modo de falha que toda a indústria já assume como inevitável — deixa de ser um evento de escalada irrestrita de privilégio e passa a ser, na pior hipótese, um **abuso contido dentro de um compartimento previamente dimensionado e auditável**.

A arquitetura não é apenas conceitual: a implementação de referência mantida neste repositório materializa cada um dos mecanismos descritos abaixo como código executável, validado contra dependências reais (motor de políticas, provedor de identidade, orquestrador de grafos de estado, modelo de linguagem real) e exercitado por uma suíte de mais de 260 testes automatizados, incluindo testes adversariais que reproduzem fisicamente os cenários de ataque discutidos na Seção 6. A Seção 7 detalha essa evidência.

1. O problema: agentes de IA como novos consumidores de sistemas corporativos

Em uma organização de porte médio a grande, capacidades de negócio já estão fragmentadas entre dezenas de sistemas: APIs REST e SOAP, funções serverless, ERPs, CRMs, bancos de dados, sistemas legados e SaaS de terceiros. Historicamente, cada nova aplicação que precisava desses sistemas passava por um gateway de API, um ESB ou uma malha de serviços — camadas que resolveram problemas de roteamento, transformação e segurança para consumidores **determinísticos**: código que chama exatamente a API que foi programado para chamar.

Agentes de IA quebram essa premissa de duas formas simultâneas:

1. **O consumidor não é mais determinístico.** Um agente decide, em tempo de execução, quais ferramentas invocar e com quais argumentos, a partir de um contexto que pode incluir texto de terceiros não confiável.
2. **O catálogo de ferramentas passa a fazer parte do comportamento do agente.** Diferente de um endpoint HTTP não documentado, uma ferramenta descrita em `tools/list` é tipicamente incorporada ao contexto do modelo e influencia diretamente o que ele tentará fazer. Controlar o que aparece nessa listagem deixa de ser apenas uma questão de documentação e passa a ser uma decisão de segurança, de custo de contexto e de qualidade de seleção de ferramenta, todas ao mesmo tempo.

Sem uma camada corporativa dedicada, o padrão observado é o mesmo em praticamente toda organização que adota agentes de forma descentralizada: cada equipe implementa seu próprio MCP Server, com seu próprio modelo de autenticação, expõe catálogos maiores do que o necessário "por conveniência", concede credenciais de backend diretamente ao agente e descobre tarde demais que revogar ou auditar esse acesso é difícil. O diagrama abaixo contrasta esse cenário com o resultado de introduzir um barramento corporativo único como ponto de publicação, descoberta e — sobretudo — de aplicação de política.




Figura 1 — Sem uma camada de governança, cada agente acumula integrações e credenciais próprias (N×M conexões, cada uma um vetor de risco e de auditoria distinto). Com o barramento, todo tráfego agêntico passa por um único ponto de aplicação de política antes de alcançar qualquer sistema corporativo.

O problema, portanto, não é "como conectar um LLM a uma ferramenta" — isso o MCP já resolve no nível de protocolo. O problema é **como disponibilizar centenas ou milhares de capacidades corporativas para múltiplos consumidores agênticos de forma consistente, governada e segura**, aceitando como premissa de projeto que o consumidor pode estar cognitivamente comprometido.

2. Ideia central e analogia estrutural

A arquitetura assume deliberadamente o papel histórico de um Enterprise Service Bus, mas o adapta a um consumidor semântico e probabilístico. A diferença não é de camadas — roteamento, mediação, transformação e resolução de serviço continuam presentes — mas de **onde a fronteira de confiança é colocada** e de **o que circula entre agente e barramento**: não apenas dados, mas descrições de capacidades que o próprio agente usa para decidir o que fazer a seguir.





Figura 2 — O ESB tradicional e o Enterprise MCP Service Bus compartilham o mesmo esqueleto (gateway → barramento → sistemas). A diferença estrutural é que o MCP Client se torna um componente de identidade explícito entre o agente e o gateway, e o que trafega da esquerda para a direita não é um payload fixo, mas uma descrição semântica de capacidade que o próprio consumidor usa para raciocinar.

Essa diferença — capacidades descritas semanticamente e consumidas por um planejador probabilístico — é a razão pela qual esta arquitetura não pode simplesmente herdar o modelo de confiança de um API Gateway tradicional. Ela precisa tratar **o que o agente pode descobrir** e **o que o agente pode executar** como dois controles distintos, e precisa garantir formalmente que nada dentro da sessão do agente — prompt, memória, resultado de ferramenta anterior, conteúdo recuperado — consiga alterar o teto de autorização estabelecido fora dele. Esses dois pontos são o assunto da próxima seção.

A visão consolidada abaixo mostra como o núcleo de segurança (barramento) se relaciona com quatro responsabilidades operacionais adicionais que a arquitetura organiza ao redor dele: governança de oferta de capacidades, personalização governada, orquestração de jornada e execução omnicanal.




Figura 3 — Visão consolidada. Duas cadeias atravessam o diagrama: uma cadeia de oferta (service owner → pipeline → registry → fabric) e uma cadeia de decisão (perfil + entitlement + ofertas filtradas → decision context → NBA → execução). Elas só se encontram no contrato MCP governado do barramento; nenhuma delas tem autoridade para contorná-lo.

A partir daqui, a legenda cromática é estável para todo o restante do documento: **âmbar** identifica a fronteira determinística de segurança (autenticação, PEP, PDP); **verde-azulado** identifica o plano de controle confiável do barramento (fabric, roteamento, resolução); **violeta** identifica governança e ciclo de vida de capacidades; **terracota** identifica a zona não confiável/probabilística (agente, conteúdo externo, canais); **azul-acinzentado** identifica sistemas de registro corporativos.

3. Mecanismos centrais (o núcleo inventivo da arquitetura)

Esta seção descreve, um a um, os mecanismos que tornam a arquitetura tecnicamente diferente de "colocar um proxy na frente de um MCP Server". Cada mecanismo é apresentado com o problema que resolve, seu funcionamento preciso, e o invariante formal que ele garante.

3.1 Client-Bound Maximum Entitlement

Problema. Em implementações ingênuas, a autorização é avaliada a partir de informação que o próprio agente, o payload de entrada ou o prompt de sistema declaram — por exemplo, um campo `agent_id` ou `role` lido do corpo da requisição. Qualquer informação nesse caminho está, por definição, sob influência do conteúdo que o modelo processa, e portanto é manipulável por *prompt injection*.

Mecanismo. Cada MCP Client possui uma identidade **autenticada por um mecanismo criptográfico independente do conteúdo da conversa** (credenciais de cliente OAuth 2.1, identidade de workload, mTLS ou equivalente). Essa identidade — nunca o `clientInfo` autodeclarado, nunca um campo do payload — é a única chave usada para resolver o `MaximumEntitlement`: o conjunto máximo de capacidades que aquela sessão pode, em qualquer circunstância, chegar a executar. Toda restrição adicional (contexto de execução, atributos do usuário final, políticas de risco) pode **reduzir** esse conjunto; nenhuma pode ampliá-lo.




Figura 4 — O teto de autorização nasce exclusivamente da identidade autenticada do client; toda outra entrada só pode restringir o conjunto efetivo, nunca alargá-lo.

Invariante. `EffectiveCapabilities(client, context) ⊆ MaximumEntitlement(client)`, para qualquer contexto, incluindo um contexto sob ataque. Formalmente, o conjunto efetivo é a interseção do teto do client com restrições de usuário, runtime, risco e recurso — nunca uma união.

Efeito técnico. Um comprometimento cognitivo do agente (prompt injection direta ou indireta, envenenamento de RAG, saída de ferramenta manipulada) deixa de ser capaz de produzir uma capacidade fora do compartimento pré-aprovado daquele client, independentemente de quão convincente seja a instrução maliciosa.

3.2 Separação entre autorização de descoberta e autorização de execução

Problema. Ocultar uma ferramenta de uma listagem (`tools/list`) reduz exposição, mas não impede, por si só, que um consumidor que já conheça o nome da ferramenta a invoque diretamente via `tools/call`. Tratar "não listado" como sinônimo de "protegido" é um erro comum e explorável.

Mecanismo. A arquitetura define dois controles independentes, aplicados em momentos diferentes do ciclo de vida da chamada, cada um reavaliado a partir da mesma identidade autenticada:




Figura 5 — Discovery authorization e execution authorization nunca compartilham o mesmo veredito implícito: uma tool escondida do catálogo continua sendo reavaliada, do zero, se alguém tentar chamá-la diretamente.

Invariante. Protegido = Oculto de descoberta não autorizada E Negado quando execução não autorizada é tentada. Nenhum dos dois controles, isoladamente, satisfaz a definição.

Efeito técnico. Elimina a classe de ataque em que um consumidor obtém o nome de uma ferramenta sensível — por engenharia reversa, vazamento de documentação, ou simplesmente por tentativa e erro — e a invoca sem nunca ter passado pela listagem filtrada.

3.3 Decision Context como envelope governado de personalização

Problema. Personalização e orquestração de jornada (o que recomendar, para quem, em qual canal, agora) tradicionalmente vivem em sistemas separados da camada de autorização, o que cria uma tentação recorrente: deixar que um modelo de propensão, um score de perfil ou uma regra de negócio decida diretamente o que o agente pode fazer — misturando relevância com permissão.

Mecanismo. Toda a informação necessária para uma decisão de orquestração é composta em um envelope único e versionado — o `DecisionContext` — **antes** de chegar ao componente que decide a próxima ação. Esse envelope combina uma visão de perfil (substituível, gerada por qualquer motor de segmentação), a identidade autenticada, os limites de entitlement já resolvidos, o conjunto de ofertas já filtrado pelo teto de autorização, e o contexto de runtime (canal, consentimento, momento). O ponto essencial é a ordem: o filtro de entitlement acontece **antes** de o envelope ser exposto ao orquestrador, nunca depois.




Figura 6 — O Decision Context é montado a partir de componentes já restritos ao teto de entitlement; o orquestrador nunca recebe, e portanto nunca pode ampliar, um universo maior do que esse.

Efeito técnico. Trocar o motor de personalização (de regras determinísticas para um modelo de ranking, de um algoritmo de clusterização para outro) não exige nenhuma mudança no núcleo de autorização, porque o contrato de entrada do orquestrador já é, por construção, um subconjunto do que é permitido. Personalização se torna um componente plugável sem se tornar uma superfície de escalada de privilégio.

3.4 Restrição monotônica: relevância nunca amplia autorização

Problema. Sistemas de recomendação, clusterização e *decisioning* são, por natureza, dinâmicos e probabilísticos — exatamente o tipo de componente que esta arquitetura trata como não confiável para fins de autorização (Seção 3.1). É preciso um mecanismo explícito que impeça esses componentes de, ainda que indiretamente, introduzir uma capacidade fora do teto do client.

Mecanismo. A arquitetura define quatro conjuntos com autoridades distintas e uma relação de contenção estritamente decrescente entre eles. Nenhum estágio posterior pode reintroduzir um elemento removido por um estágio anterior.



Figura 7 — Contenção estrita entre os quatro conjuntos que a arquitetura nunca deixa colapsar em um só. Cada camada só pode reduzir a anterior; a autoridade que decide cada camada é diferente (registro, entitlement manager/PDP, filtro de ofertas, orquestrador).

Conjunto	Pergunta que responde	Autoridade	Pode ampliar o de fora?
GlobalCatalog	O que foi publicado e está ativo?	Registry + Fabric	—
MaximumEntitlement	Qual é o teto deste client?	Entitlement Manager + PDP	Não
FilteredOfferings	O que é elegível agora?	Offering Filter	Não

3.7 Publicação governada de capacidades (supply chain de capabilities)

Problema. Capacidades registradas manualmente, sem dono definido, sem classificação de risco e sem gate de política, tendem a se acumular como dívida técnica invisível: ninguém sabe ao certo o que está exposto, para quem, nem sob qual risco.

Mecanismo. Toda capacidade nasce de um manifesto declarativo (nome canônico, domínio, versão, esquema de entrada/saída, dono, classificação de risco e de dado, efeitos colaterais, idempotência, entitlements exigidos, requisitos de aprovação) e só se torna resolvível pelo barramento depois de atravessar um pipeline de publicação com gates obrigatórios de esquema, risco e política.




Figura 10 — Nenhuma capacidade alcança o estado "ativa e resolvível" sem passar mecanicamente pelos quatro gates. A implementação de referência deste repositório reforça essa regra no nível de código: nada alcança o estado ativo sem antes passar por revisão.

Efeito técnico. Torna a superfície de capacidades expostas ao ecossistema agêntico um ativo administrado com ciclo de vida, versionamento e responsável — não uma lista que cresce organicamente por registro manual.

3.8 Rastreabilidade correlacionada de ponta a ponta

Problema. Em um sistema com múltiplos componentes de decisão (perfil, entitlement, filtro de ofertas, orquestrador, gateway, backend), a ausência de uma chave de correlação estável torna praticamente impossível reconstruir, depois do fato, por que uma ação específica foi tomada ou negada.

Mecanismo. Cada decisão relevante — resolução de perfil, resolução de entitlement, decisão de política, cálculo de NBA, chamada MCP, resultado de backend — carrega identificadores versionados e correlacionáveis (versão de perfil, versão de entitlement, id de decisão, id de decisão de política, id de requisição MCP) propagados como campos de primeira classe através de toda a cadeia, nunca reconstruídos *a posteriori* por correlação heurística de timestamp.

Efeito técnico. Toda decisão de autorização é determinística e auditável (Axioma 10, Seção 9): dado um evento de negócio, é possível reconstruir exatamente qual versão de política, qual entitlement e qual decisão de orquestração levaram a um resultado específico — um requisito indispensável tanto para investigação de incidentes quanto para demonstrar conformidade.

4. Arquitetura de componentes

A tabela e o diagrama a seguir consolidam a responsabilidade de cada componente e as fronteiras de confiança entre eles. Três zonas lógicas organizam o sistema: a zona não confiável/probabilística (agente e tudo que ele processa), a zona determinística de segurança (autenticação, PEP, PDP, auditoria) e a zona de integração corporativa confiável (fabric e sistemas de backend).




Figura 11 — A fronteira de confiança fica entre o MCP Client e a autenticação de workload — nunca dentro da zona onde o agente raciocina. Nenhuma seta atravessa essa fronteira em sentido inverso.

Componente	Responsabilidade central	Autoridade sobre
Agent / Agent Host	Interpretar intenção, planejar, selecionar ferramentas, orquestrar sessão de modelo	Nenhuma decisão de segurança
MCP Client	Autenticar-se perante o barramento; carregar a identidade que define o teto de privilégio	O compartimento máximo daquela sessão
MCP Gateway / PEP	Aplicar autenticação, filtragem de descoberta, reautorização de execução, rate limiting, auditoria	Enforcement — nunca delega a decisão ao modelo
PDP / Policy Engine	Avaliar política de entitlement (a tool pertence ao teto?) e política de transação (o argumento é aceitável?)	Decisão determinística ALLOW / DENY / REQUIRE_APPROVAL
Global Capability Registry	Catálogo administrativo completo, com ciclo de vida, dono e classificação de risco	Definição do que existe e está ativo
Enterprise MCP Fabric	Roteamento, mediação de protocolo, transformação, resolução de backend	Execução da capacidade já autorizada
Entitlement Manager	Resolver, versionar e revogar o <code>MaximumEntitlement</code> por identidade autenticada	O cardápio máximo por client

Componente	Responsabilidade central	Autoridade sobre
Profile Intelligence	Produzir uma visão de perfil substituível (segmentos, scores, atributos)	Relevância — nunca autorização
Offering Filter	Intersectar catálogo ativo, entitlement e contexto para produzir candidatas elegíveis	O universo do qual a NBA pode escolher
Service Orchestrator	Manter estado de jornada e calcular a Next Best Action	A ação pretendida — não a autorização de executá-la
Agent Runtime	Despachar a NBA, gerenciar sessão, canal e handoff entre agentes	Execução coordenada, nunca emissão de credencial

O princípio operacional que amarra toda a tabela: **cada componente tem autoridade sobre exatamente uma pergunta**. O Orchestrator decide *qual* ação tentar; o Gateway/PDP decide *se* ela pode ser executada; o backend continua decidindo sobre seus próprios recursos. Nenhum desses três papéis é intercambiável, e um comprometimento de qualquer um deles não concede automaticamente a autoridade dos outros dois.

5. Fluxos operacionais de ponta a ponta

5.1 Descoberta filtrada (`tools/list`)




Figura 12 — A identidade é autenticada antes de qualquer filtragem; o agente nunca escolhe, declara ou influencia o entitlement que delimita o que ele verá.

5.2 Execução reautorizada (tools/call)




Figura 13 — `tools/call` é reautorizado do zero, em dois passos (entitlement, depois transação), independentemente do que `tools/list` retornou.

5.3 Fluxo orquestrado — de perfil a execução, sem fundir autoridades




Figura 14 — Perfil, entitlement e ofertas filtradas alimentam o cálculo da NBA, mas a decisão do orquestrador segue sendo reautorizada, chamada a chamada, pelo mesmo par Gateway/PDP do fluxo de execução simples.

6. Modelo de ameaças e defesa em profundidade

A arquitetura não assume que técnicas de *guardrail* eliminarão *prompt injection* — ela assume o oposto: que o comprometimento cognitivo do agente é um modo de falha plausível e recorrente, e pergunta apenas: **se o agente estiver comprometido, qual é o máximo que ele consegue fazer?** A resposta desejada é: no máximo aquilo que o MCP Client já estava autorizado a fazer, sujeito ainda a política de transação, aprovação humana quando aplicável e à autoridade final do backend.

6.1 Cenário — prompt injection tentando escalar privilégio




Figura 15 — O PEP nunca consulta o modelo para decidir; a negação acontece unicamente porque a capacidade solicitada não pertence ao teto do client, independentemente do quão convincente foi a instrução maliciosa.

A arquitetura distingue duas classes de risco residual, com mitigações diferentes para cada uma:

Classe	Definição	Exemplo	Mitigação principal
Privilege escalation	Tentar acessar uma capacidade fora do entitlement	<code>Sales.Read</code> tentando <code>finance.createPayment</code>	PEP + entitlement do client (Seção 3.1)
Privilege abuse	Usar de forma maliciosa uma capacidade já legítima	<code>email.send</code> autorizado, instruído a vaziar dados para um destinatário externo	Política de argumento/recurso, allowlist de destino, aprovação humana, limites transacionais

Privilege escalation é resolvido estruturalmente pelo modelo de entitlement; privilege abuse exige uma segunda linha de defesa sobre argumentos e recursos, porque a ferramenta em si é legítima — o problema está no uso.

6.2 Defesa em profundidade




Figura 16 — Nenhuma camada isolada resolve o problema completo; a garantia vem da composição. Uma falha em L5 (política de argumento), por exemplo, ainda é contida por L6 (aprovação) e L7 (autorização do backend).

6.3 Contenção de raio de impacto (blast radius)

A decisão de projeto com maior efeito prático sobre o risco residual é o **tamanho do compartimento por client**. Um único client de altíssimo privilégio compartilhado por muitos agentes concentra risco; múltiplos clients segmentados por domínio e por nível de risco limitam o impacto de qualquer comprometimento individual a um raio previsível.




Figura 17 — O mesmo número de agentes produz raios de impacto radicalmente diferentes dependendo unicamente de como os MCP Clients são segmentados. Segmentar por domínio e por classificação de risco — não por agente — é a variável de projeto que mais reduz o impacto esperado de um comprometimento.

Cada capacidade publicada carrega uma classificação de risco explícita, usada tanto para segmentar clients quanto para decidir onde aprovação humana é obrigatória:

Tier	Natureza	Exemplo	Controle esperado
R0	Descoberta / público	metadado não sensível	autenticação opcional conforme contexto

Tier	Natureza	Exemplo	Controle esperado
R1	Leitura	busca, consulta	entitlement + auditoria
R2	Escrita	criar/atualizar registro	entitlement + política de argumento
R3	Alto impacto	aprovar crédito, executar pagamento	entitlement dedicado + política + aprovação
R4	Destrutivo / restrito	encerrar conta, excluir registro	client dedicado + autenticação forte + aprovação + controles de backend

7. Evidência de implementação: da arquitetura ao sistema em funcionamento

Um documento de arquitetura ganha peso técnico real quando cada mecanismo descrito nas seções anteriores corresponde a um componente que existe, roda e é exercitado por testes contra dependências reais — não *mocks*. A implementação de referência mantida neste repositório cobre integralmente os mecanismos das Seções 3 a 6, com a seguinte composição:

7.1 Dependências reais exercitadas

Dependência	O que valida	Natureza da validação
Motor de políticas (execução real, não simulada)	As duas políticas de decisão descritas na Seção 3.1 — entitlement e transação	Testes unitários da política + testes de integração ponta a ponta
Provedor de identidade OAuth 2.1 / OIDC (containerizado, real)	Emissão e validação de credenciais de client, <i>token exchange</i> para identidade de saída (Seção 3.6)	Testes de integração contra o provedor real, incluindo cenários negativos de audiência
Orquestrador de grafo de estado com checkpoint persistente	O fluxo de perfil → entitlement → ofertas filtradas → NBA → aprovação (Seção 5.3), incluindo pausa e retomada de aprovações	Testes unitários e de ponta a ponta, incluindo prova de que retomar um checkpoint pausado não reexecuta nós já concluídos
Modelo de linguagem real, com <i>tool-calling</i>	O cenário de contenção de prompt injection (Seção 6.1), reproduzido fisicamente contra um modelo real, não simulado	Teste de ponta a ponta com chamada de ferramenta real
Ambiente containerizado completo	Segmentação de rede entre domínios, comportamento <i>fail-closed</i> , rastreamento correlacionado entre serviços distintos	Subida completa de todos os serviços e verificação de que nenhum domínio expõe porta além do gateway
Plataforma de observabilidade de LLM, auto-hospedada	Exportação real de telemetria de execução do agente (<i>spans</i> de chamada de ferramenta e de geração)	Validação funcional contra a pilha real

7.2 Extensão da cobertura de testes

A suíte de testes da implementação de referência ultrapassa **260 casos automatizados**, cobrindo quatro categorias: testes unitários de cada componente, testes de contrato entre componentes, testes de ponta a ponta contra dependências reais, e uma categoria dedicada de **testes adversariais** que reproduz fisicamente os cenários de ataque descritos na Seção 6 — incluindo tentativas diretas de escalada de privilégio via *prompt injection*, chamada direta de ferramenta não listada, *replay* de aprovações já consumidas sob concorrência real de múltiplas threads, e verificação formal (por geração de milhares de casos) de que o filtro de ofertas nunca reintroduz uma capacidade fora do entitlement do client.

Um subconjunto dedicado de **testes de aceite de segurança**, executado contra o ambiente containerizado completo, verifica de ponta a ponta as garantias centrais da arquitetura: descoberta não autorizada nunca retorna uma capacidade fora do teto; chamada direta e não autorizada é negada mesmo conhecendo o nome exato da ferramenta; nenhum conteúdo de prompt altera o teto máximo de entitlement; revogação de política impede novas execuções; acesso direto ao *fabric* contornando o gateway falha; e a simulação de uma credencial de client roubada demonstra que o atacante nunca excede o entitlement daquele client específico.

7.3 Domínios de exemplo e cobertura de risco

A implementação de referência demonstra a segmentação por domínio e por risco (Seção 6.3) com dois domínios de negócio completos — um domínio de vendas e um domínio financeiro — cobrindo capacidades dos quatro primeiros níveis de risco (R1 a R4), incluindo uma capacidade R3 com ciclo completo de aprovação humana: negação inicial, aprovação externa fora de banda, execução, e nova tentativa idêntica corretamente negada por *replay* (a mesma aprovação nunca é consumida duas vezes).

7.4 Achados de engenharia registrados honestamente

Uma implementação de referência séria também documenta o que **não** foi resolvido, em vez de apresentar apenas o caminho feliz. Dois achados de concorrência real, identificados e corrigidos durante a implementação, ilustram o tipo de detalhe que só aparece ao transformar a arquitetura em código:

- Uma condição de corrida real no gate de aprovação de operações de alto risco: sob concorrência de múltiplas tentativas simultâneas, duas requisições podiam observar a mesma aprovação como "concedida" antes que qualquer uma a marcasse como "consumida" — permitindo, em tese, o uso duplo de uma aprovação de uso único. Corrigido com uma seção crítica dedicada e comprovado sob carga concorrente real.
- Uma falha do coletor de auditoria podia, antes da correção, se propagar como um erro de servidor em uma operação já decidida — violando o princípio de que uma falha de observabilidade não deve bloquear uma decisão de baixo risco já tomada.

Limitações estruturais também são declaradas explicitamente: a implementação de referência não inclui um mecanismo dedicado de anti-*replay* de requisição (mitigado por credenciais de vida curta e auditoria completa) nem limitação de taxa no gateway (mitigado apenas por detectabilidade *a posteriori*, nunca por prevenção em tempo real) — ambos descritos como extensões de produção necessárias, não como lacunas ocultas.

8. Posicionamento comparativo

Dimensão	ESB tradicional	API Gateway	Enterprise MCP Service Bus
Consumidor principal	Aplicações	Aplicações / APIs	Agentes / MCP Clients
Natureza do contrato	Serviço / mensagem	API HTTP	Capacidade semântica (tool)
Descoberta	Catálogo de serviços	Catálogo de API	Catálogo visível ao agente, filtrado por entitlement
Descrição semântica	Limitada	OpenAPI / metadados	Central — influencia diretamente o planejamento do consumidor
Aplicação de política	Comum	Central	Obrigatória, em dois estágios (descoberta e execução)
Prompt injection como ameaça	Não aplicável	Indireta	Modelo de ameaça central de projeto
Filtragem de catálogo por entitlement	Incomum	Possível	Elemento arquitetural obrigatório
Raio de impacto por identidade	Possível	Possível	Princípio central de projeto (Seção 6.3)

A diferença que a tabela não captura sozinha é qualitativa: um ESB ou um API Gateway não precisam assumir que seu consumidor pode ser enganado por texto. Esta arquitetura assume exatamente isso como premissa de projeto — e é essa premissa que determina cada um dos oito mecanismos da Seção 3.

9. Conjunto formal de invariantes

As regras abaixo são o contrato inegociável da arquitetura. Qualquer implementação, extensão ou integração que viole uma delas deixa de satisfazer esta arquitetura, independentemente de quão sofisticada seja a camada de inteligência construída sobre ela.

#	Invariante
1	O agente não é uma autoridade de segurança.
2	A identidade autenticada do MCP Client define o conjunto máximo de capacidades.
3	Informação controlada pelo agente pode restringir, mas nunca ampliar, autorização.
4	<code>EffectiveCapabilities</code> $\subseteq$ <code>ClientEntitlement</code> , sempre.
5	Filtragem de descoberta é minimização; autorização de execução é a fronteira real de aplicação.
6	Autorização de uma tool não implica autorização irrestrita da transação que ela executa.
7	O Gateway não pode ser contornável por nenhum caminho de rede ou protocolo.
8	A confiança do backend no barramento permanece limitada e explícita — nunca passthrough cego.
9	Um client comprometido deve ter um raio de impacto previsível e dimensionado.

#	Invariante
10	Toda decisão de segurança é determinística e auditável.
11	Inteligência de perfil pode ordenar ou reduzir candidatas; nunca pode conceder capacidades.
12	Uma Next Best Action é uma intenção de orquestração, não uma decisão de autorização.
13	Capacidades são publicadas uma vez e reutilizadas apenas por assinatura e aplicação governadas.

10. Modelo de maturidade e trajetória de adoção

A arquitetura é desenhada para adoção incremental — nenhum estágio exige que o seguinte já exista.




Figura 18 — Cada fase entrega valor isolado. Uma organização pode operar de forma estável na Fase 1 ou 2 por tempo indefinido antes de avançar.

Fase	Entrega central
0 — Princípios e contratos	Invariantes de segurança, metadado de capacidade, modelo de client profile, modelo de identidade, esquema de auditoria
1 — Piloto somente leitura	Um domínio, poucas capacidades R1, descoberta filtrada, reautorização de execução, auditoria completa
2 — Operações de escrita	Política de argumento, autorização de backend, limites transacionais, idempotência, aprovação seletiva
3 — Fabric multi-domínio	Servidores de domínio, registro central, governança de namespace, automação de ciclo de vida
4 — Personalização e orquestração governadas	Contrato de perfil versionado, Entitlement Manager, Offering Filter, Decision Context, Service Orchestrator, Agent Runtime, correlação de ponta a ponta
5 — Escala corporativa	Provisionamento automatizado de client, política como código, revisão de entitlement, detecção avançada de anomalia, governança de custo

11. Glossário

Agent — Componente de IA que interpreta contexto, planeja e solicita execução de capacidades. Não é autoridade de segurança.

Agent Runtime — Camada que despacha a NBA, gerencia sessão, contexto mínimo e handoff entre agentes e canais.

Blast radius (raio de impacto) — Impacto máximo esperado em caso de comprometimento de uma identidade ou componente.

Capability / Tool — Operação semântica exposta a um consumidor MCP.

Client-Bound Capability View — Catálogo MCP filtrado de acordo com o entitlement do client autenticado.

Decision Context — Envelope versionado com visão de perfil, identidade autenticada, limites de entitlement, ofertas filtradas e contexto de runtime, entregue ao Service Orchestrator.

Effective Capabilities — Subconjunto do Maximum Entitlement disponível em um contexto específico.

Entitlement Manager — Componente que resolve, versiona e revoga o Maximum Entitlement e os cardápios MCP personalizados.

Enterprise MCP Fabric — Camada de integração que publica, resolve e roteia capacidades MCP sobre serviços corporativos.

Global Capability Registry — Catálogo administrativo completo de capacidades governadas, com ciclo de vida e dono.

Maximum Entitlement — Teto de capacidades associado a um MCP Client autenticado.

Next Best Action (NBA) — Ação selecionada pelo Orchestrator para um contexto e objetivo de jornada; não constitui, por si só, autorização de execução.

Offering Filter — Componente que intersecta catálogo ativo, entitlement e contexto para produzir capacidades elegíveis.

PDP — Policy Decision Point — Componente que calcula decisões de autorização a partir de política e atributos confiáveis.

PEP — Policy Enforcement Point — Componente que aplica, de forma determinística, as decisões de autorização.

Privilege abuse — Uso malicioso ou indevido de uma capacidade legitimamente concedida.

Privilege escalation — Aquisição de uma capacidade fora do entitlement.

Profile Intelligence — Capacidade substituível que deriva segmentos, clusters ou scores de perfil; informa relevância, nunca concede autorização.

Prompt injection — Ataque que introduz instruções maliciosas no contexto processado por um modelo de linguagem.

Service Orchestrator — Componente que coordena estado e objetivo de jornada e calcula a Next Best Action a partir de Decision Context, regras, guardrails e memória.

12. Síntese final

A mudança de perspectiva que esta arquitetura propõe pode ser resumida em uma única frase: **o agente não recebe acesso a um barramento corporativo e depois decide o que fazer com ele; o MCP Client recebe, antecipadamente, um compartimento de capacidades já governado, e o agente só pode operar dentro desse compartimento.**

Essa inversão — mover a decisão de autorização para antes e para fora da camada onde o modelo raciocina — é o que permite usar MCP como uma interface corporativa compartilhada, acessível a múltiplos agentes e casos de uso, sem transferir a raiz de confiança da organização para um componente probabilístico. Ao redor desse núcleo, a arquitetura organiza publicação governada de capacidades, personalização substituível, orquestração de jornada e execução omnicanal — cada uma dessas camadas plugável e evolutiva, nenhuma delas com autoridade para alterar o teto de autorização estabelecido pela identidade do client.

O objetivo final não é tornar o agente confiável. É tornar seguro o fato de que ele não é — e a implementação de referência mantida neste repositório existe precisamente para demonstrar que essa garantia é possível de construir, testar e operar como software real, não apenas descrever como princípio de arquitetura.
